

Artificial Intelligence Final Project: Finetuning BERT

홍성주

Soongsil University
Computer Science Engineering

[20221528]

Abstract

본 프로젝트의 목표는 *Pre-trained BERT* 모델을 *IMDB* 영화 리뷰 데이터셋에 맞춰 *Fine-tuning* 하여, 리뷰의 감성 (긍정/부정)을 분류하는 모델을 구축하는 것이다. 기본 모델로 *bert-base-uncased*를 사용하였으며, 제한된 데이터와 모델 크기 내에서 *Generalization* 성능을 극대화하기 위해 다양한 *hyperparameter tuning*과 *Regularization* 기법을 적용했다.

특히 *Cosine Learning Rate Scheduler*와 *Label Smoothing*을 도입하여 *Overfitting*을 방지하고 학습 안정성을 높였다. 또한, *Random Seed*에 따른 성능 편차를 분석하여 최적의 초기화 값을 선정하였다. 그 결과, *Validation Set*에서 **94.56%**의 높은 정확도(*Accuracy*)를 달성하였으며, 이는 단순 베이스라인 대비 유의미한 성능 향상이다.

1. Introduction

NLP 분야에서 Transformer 기반의 BERT는 다양한 다운스트림 태스크에서 뛰어난 성능을 보여주고 있다. 본 과제에서는 BERT 모델 위에 분류를 위한 레이어(Classification Head)를 추가하고, IMDB 데이터셋(50,000개의 영화 리뷰)을 사용하여 이진 분류(Binary Classification) 문제를 해결한다.

핵심 목표는 학습 데이터(Train Set)에만 잘 동작하는 것이 아니라, 보지 못한 데이터(Hidden Test Set)에서도 높은 성능을 내는 Robust한 모델을 만드는 것이다. 이를 위해 단순한 학습을 넘어, 문장 길이(Sequence Length) 확장, 학습률 스케줄링(Scheduler), 손실 함수(Loss Function) 최적화 등 다양한 실험을 수행하였다.

2. Model Structure & Learning Method

2.1. Model Architecture

- **Pre-trained Model:** *bert-base-uncased* (12 Layers, 768 Hidden Size, 12 Heads)를 사용하였다. 과제 규정에 따라 모델의 구조나 사전 학습된 Weights는 변경하지 않았다.
- **Classification Head:** BERT의 [CLS] 토큰 출력값

(Pooled Output)을 입력으로 받아, 최종 2개의 클래스 (Positive/Negative)를 예측하는 Linear Layer를 설계하였다.

- **Dropout:** overfitting 방지를 위해 Linear Layer 이전에 Dropout($p=0.1$)을 적용하였다.

2.2. Data Processing

- **Max Sequence Length:** IMDB 리뷰는 문장 길이가 긴 경우가 많다. 일반적인 128이나 256 길이로 자를 경우 정보 손실(Information Loss)이 발생하여 성능이 저하됨을 확인하였다. 따라서 BERT가 허용하는 최대 길이인 512로 설정하여 리뷰의 모든 문맥을 학습하도록 했다.
- **Batch Size:** 메모리 효율성과 학습 안정성을 고려하여 16으로 설정하였다.

2.3. Optimization Strategy

- **Optimizer:** AdamW (Adam with Weight Decay)를 사용하여 가중치 감쇠 효과를 주었다.
- **Loss Function (Label Smoothing):** 일반적인 CrossEntropyLoss 대신 **Label Smoothing (factor=0.1)**을 적용하였다. 이는 정답을 1.0(Hard Label)이 아닌 0.9(Soft Label)로 학습하게 함으로써, 모델이 학습 데이터에 대해 지나치게 확신(Overconfidence)하는 것을 막고 일반화 성능을 높이는 핵심 기법으로 사용되었다.
- **Scheduler:** 학습률을 일정하게 유지하거나 선형으로 줄이는 대신, Cosine Schedule (Warmup 없이 감소)을 사용하여 학습 후반부에 미세한 최적점을 찾도록 유도하였다.

3. Experimental Process (Trial-and-Error)

최고의 성능을 달성하기 위해 다음과 같은 단계적 실험을 진행하였다.

Experiment ID	Method / Changes	Val Acc.	Note
Baseline	Linear Schedule, 4 Epochs	94.20%	Overfitting
Trial 1	Dropout 0.3	94.30%	Slow conv.
Trial 2	Cosine Scheduler	94.45%	Stable
Final (Trial 3)	Seed 2025 + Label Smooth	94.56%	Best

Table 1. Summary of the experimental process and performance improvements.

tuned_bert.pth)을 제출하였다. 이 모델은 Hidden Test Set에서도 우수한 일반화 성능을 보일 것으로 기대된다.

References

Soongsil University

3.1. Baseline (Linear Schedule)

초기 실험에서는 Linear Scheduler, Epoch 4, Learning Rate $2e-5$ 의 표준 설정을 사용하였다.

결과: 약 94.2% 수준의 Accuracy를 기록하였으나, 특정 Epoch 이후 성능이 정체되거나 소폭 하락하는 경향을 보였다.

3.2. Trial 1: Handling Overfitting (Dropout)

성능 정체 원인을 overfitting으로 가정하고, Dropout 비율을 기존 0.1에서 0.3으로 증가시키는 실험을 진행하였다.

결과: overfitting은 억제되었으나, 학습 속도가 느려지고 최종 정확도(94.3%)가 기대만큼 크게 상승하지 않았다. 따라서 Dropout은 다시 0.1로 유지하되, 다른 정규화 기법인 Label Smoothing을 도입하기로 결정하였다.

3.3. Trial 2: Scheduler Optimization (Cosine)

모델이 Local Minima에 빠지지 않고 더 좋은 해를 찾도록 하기 위해, 학습률 스케줄러를 Linear에서 **Cosine Scheduler**로 변경하였다.

결과: 학습 초반에는 빠르게 수렴하고, 후반부에는 학습률이 부드럽게 감소하면서 성능이 94.4% ~ 94.5% 구간으로 향상되었다.

3.4. Trial 3: Seed Tuning (Final Strategy)

딥러닝 모델의 초기 Initialization과 데이터 배치의 무작위성에 따른 성능 편차를 확인하기 위해, 여러 Random Seed (42, 777, 2025 등)를 테스트하였다.

결과: 동일한 하이퍼파라미터 설정에서도 Seed에 따라 약 0.1 ~ 0.2%의 성능 차이가 발생함을 확인하였다.

최종 선택: Seed 2025 환경에서 Cosine Scheduler와 Label Smoothing을 함께 적용했을 때, Epoch 3 시점에서 가장 높은 검증 정확도를 기록하였다.

4. Conclusion

본 프로젝트에서는 BERT 모델의 미세 조정 성능을 극대화하기 위해 데이터 길이 확장, 손실 함수 개선(Label Smoothing), 학습률 스케줄링(Cosine), 그리고 튜닝을 수행하였다.

그 결과, overfitting을 효과적으로 제어하면서도 학습 데이터의 정보를 최대한 활용할 수 있었고, 최종적으로 Validation Accuracy 0.9456을 달성한 모델(fine-